


# **TRABAJO FINAL: RECONOCIMIENTO DE EMOCIONES**

**Materia Optativa: Introducción a Sistemas Inteligentes**

**Profesores: Mg. Rosa Macaione – Lic. Carlos Ismael Orozco**

**Alumno: Barboza Héctor Emanuel**

## *Sistema Nervioso y el Cerebro*



Es:

- Complejo
- No Lineal
- Paralelo


# ¿QUE SON LAS NEURONAS?

## Comparación con Redes Neuronales Humanas


Se estima que el cerebro humano contiene mas de cien mil millones de neuronas y sinapsis en el sistema nervioso humano.

Tiene los Siguietes componentes:

- ✓ Soma o cuerpo
- ✓ Sinapsis
- ✓ Dentrilas
- ✓ Axón



## Redes Neuronales Artificiales (RNA) o Artificial Neural Network (ANN)



Es un modelo computacional basado en un conjunto de neuronas que emulan el funcionamiento del cerebro humano.

Es un paradigma o un nuevo sistema de procesamiento y de tratamiento de la información compuesta por neuronas Artificiales

Una red neuronal es apta para resolver problemas que no tienen un algoritmo claramente definido para transformar una entrada en una salida.

Esta inspirado en el en el Sistema Neuronal o Nervioso Biológico.

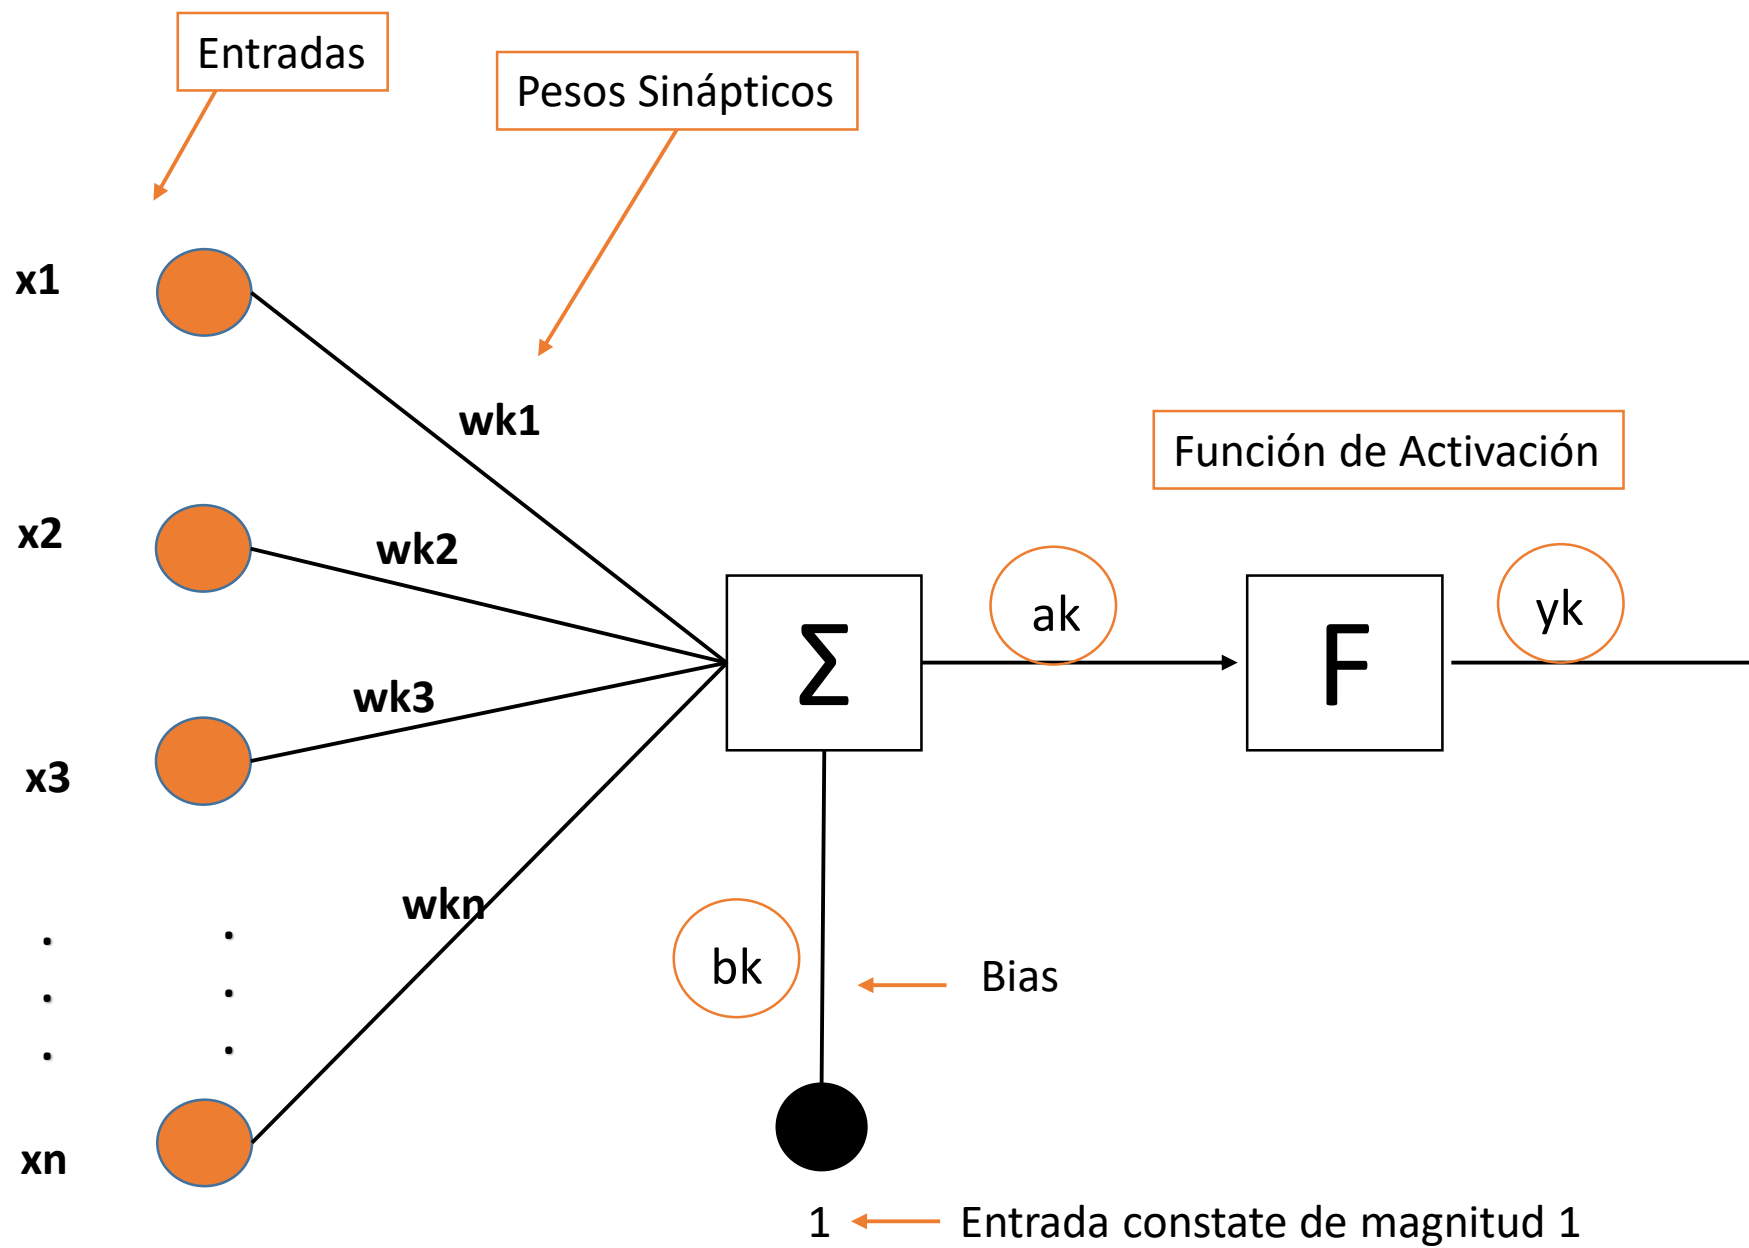


1 NURONA → Es un componente relativamente Simple  
Miles de Millones de NEURONAS → Forman un poderoso Sistema

### Características:

- ☐ Aprendizaje Adaptable
  - Red en Entrenamiento
  - Red Entrenada
  - Conocimiento Adquirido
- ☐ Auto-Organización
- ☐ Tolerancia a Fallos
- ☐ Flexibilidad
- ☐ Tiempo Real





$$S_k = w_{k1} * x_1 + w_{k2} * x_2 + \dots + w_{kn} * x_n$$


$$S_k = \sum_{i=1}^n w_{ki} * x_i$$

$$a_k = \sum_{i=1}^n w_{ki} * x_i + b_k$$

$$a_k = \sum_{i=0}^n w_{ki} * x_i$$


$$a_k = S_k + b_k$$

$$y_k = F(a_k)$$







Lineal :  $y=k*a$





Sigmoide



Escalón:  $y=0$  si  $a<0$   
 $y=1$  si  $a \geq 0$

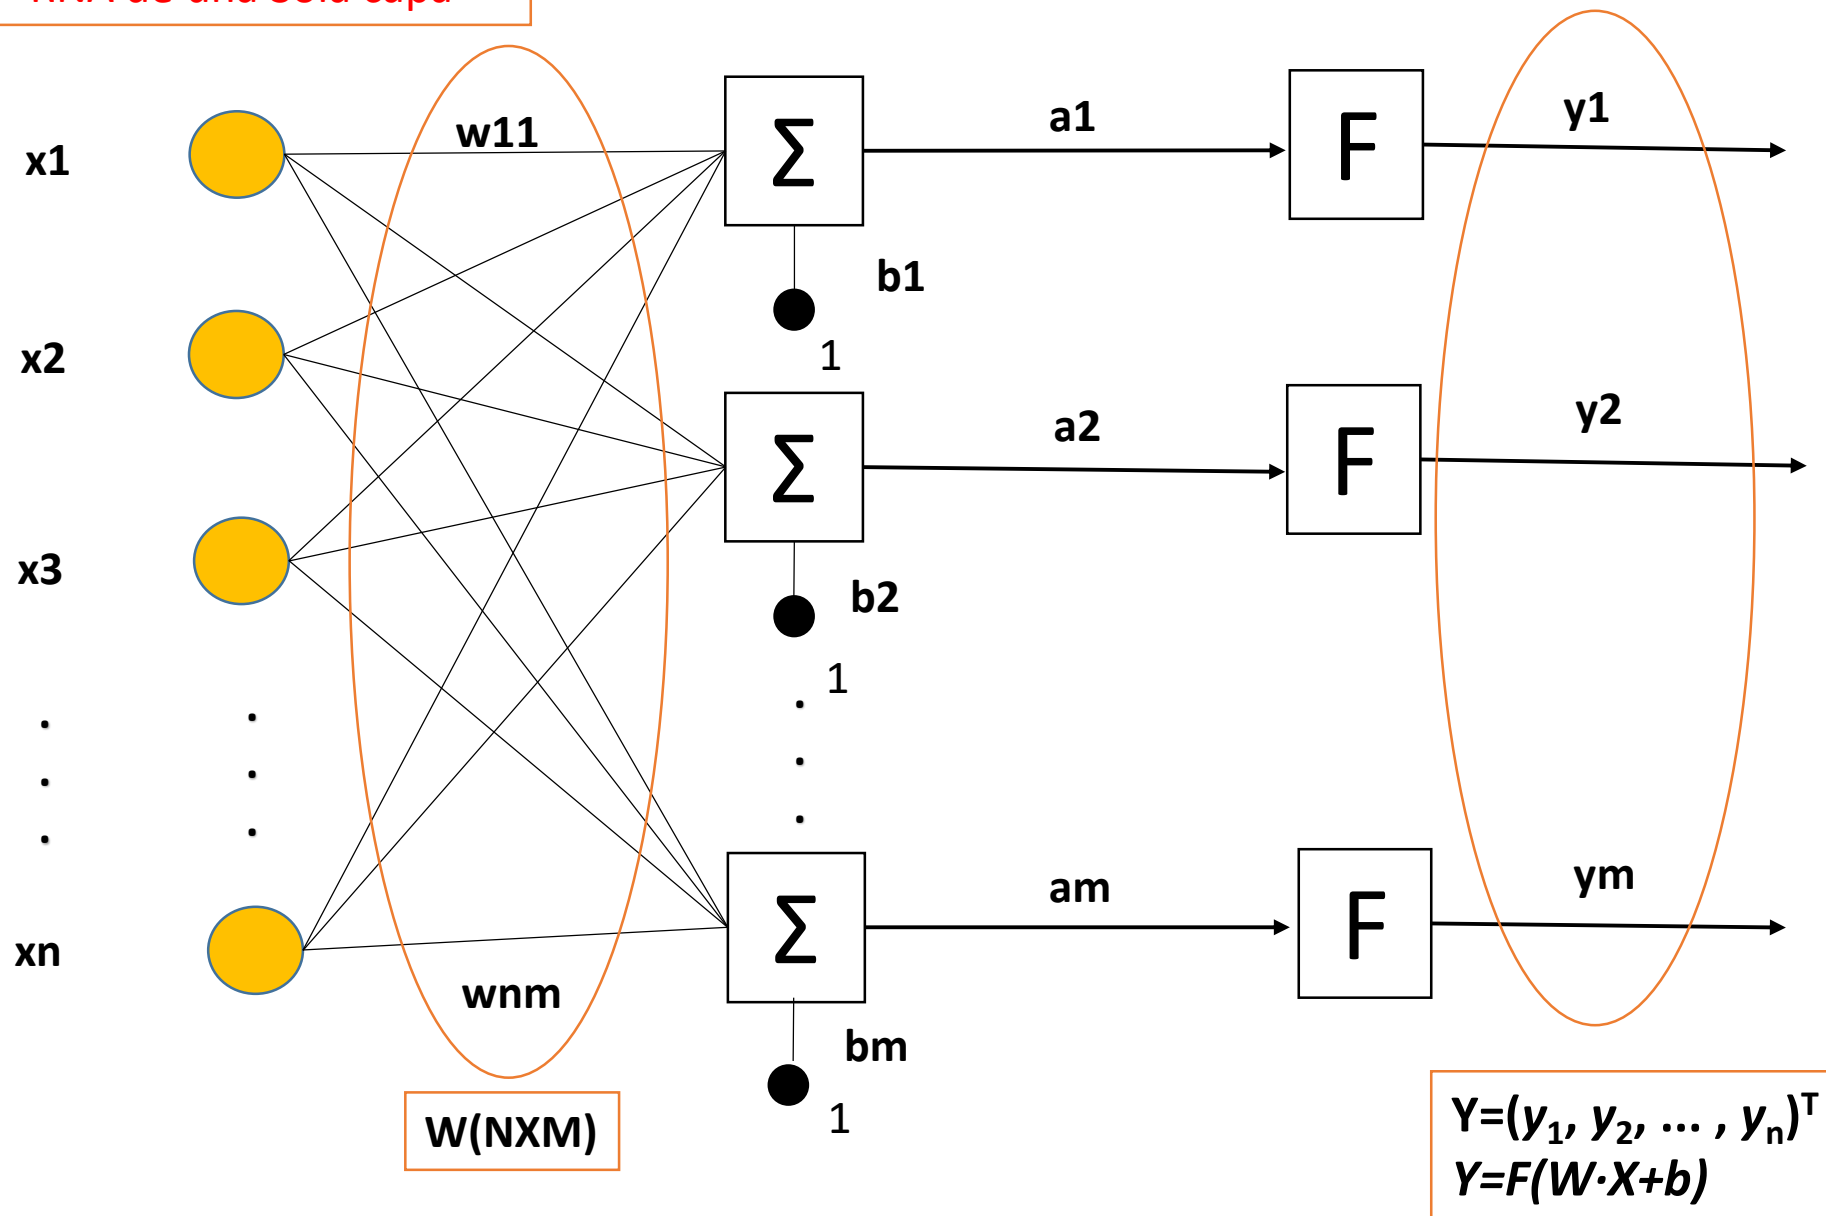


Lineal Mixta



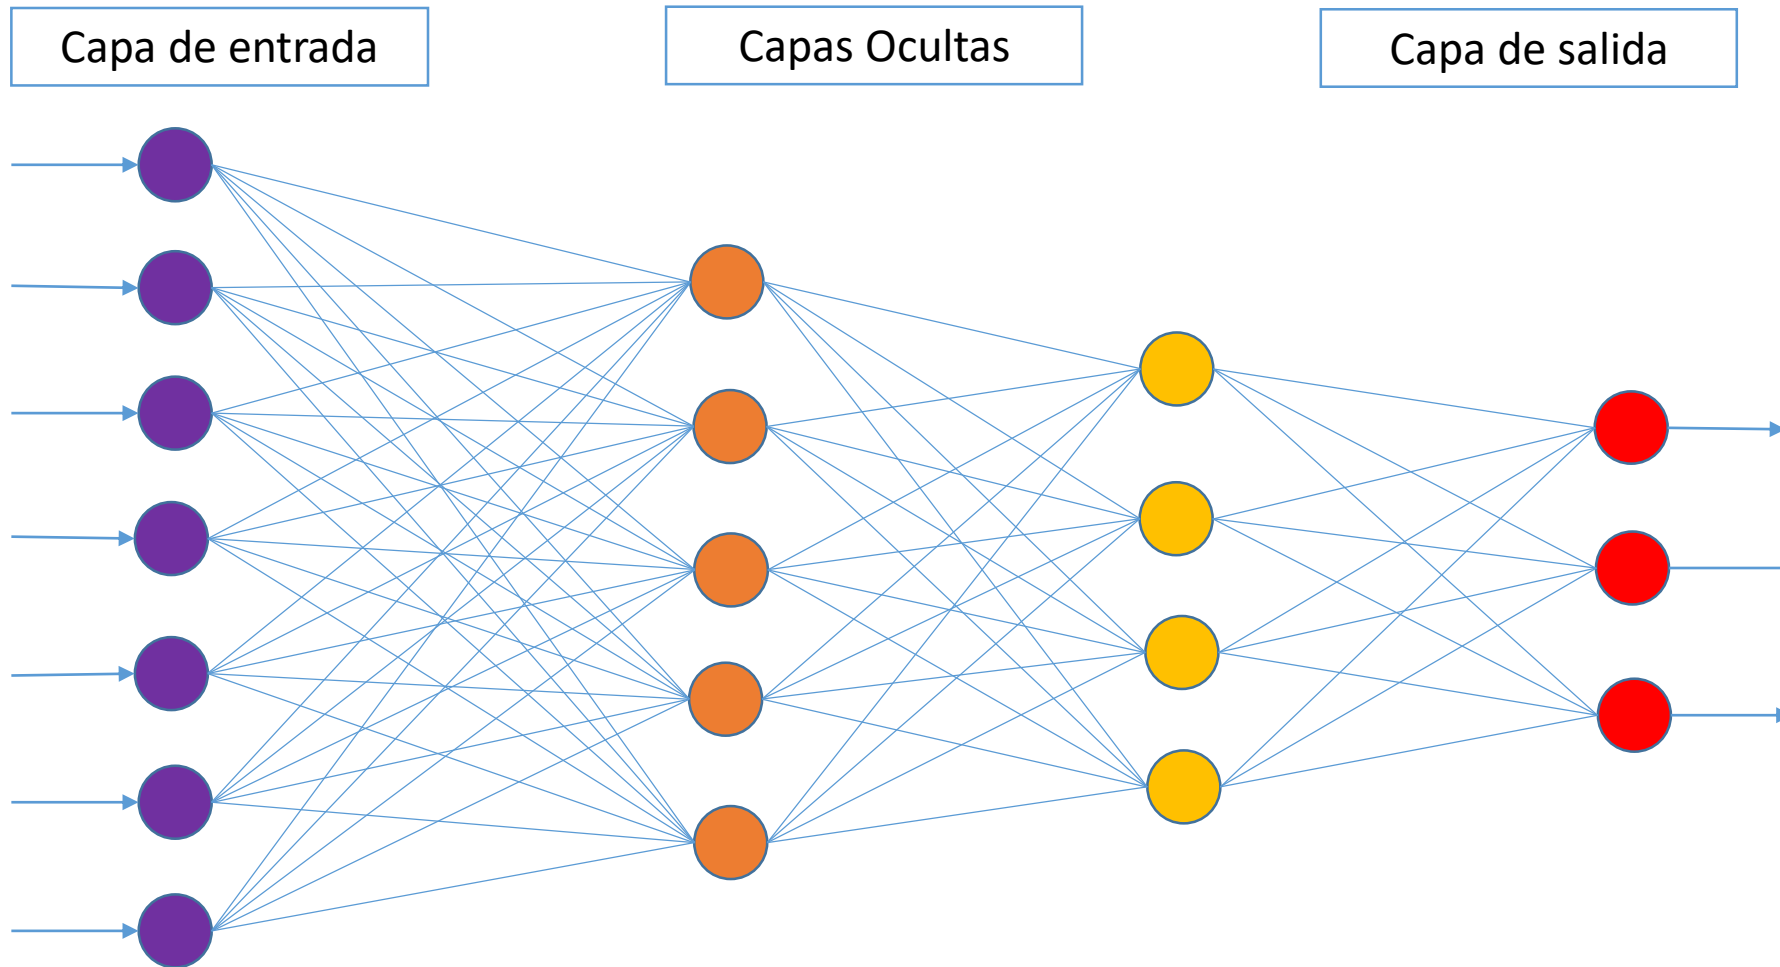
Gaussiana

## RNA de una Sola capa



## RNA Multicapa

Las neuronas se interconectan en tres tipos de capas:





## ❑ Redes Feedforward :

Las mas conocidas son:

- ✓ Perceptron
- ✓ Adaline
- ✓ Madaline
- ✓ Backpropagation

## ❑ Redes Feedback:



## Tipo de Entrenamiento

### ☐ Supervisado:

En este caso un experto asesora el entrenamiento

Pares de entrenamiento: entrada - salida deseada.

Error por cada par que se utiliza para ajustar parámetros

### ☐ No supervisado:

Solamente conjunto de entradas.

Salidas: la agrupación o clasificación por clases

### ☐ Reforzado o por esfuerzos:

Premios y castigos

## Armando una topología

Cuando armamos una topología de una red neuronal hay que tener en cuenta algunas cosas como por ejemplo:

- ✓ El numero de capas
- ✓ El numero de neuronas por capa
- ✓ Tipo de conexiones. Normalmente, todas las neuronas de una capa reciben señales de la capa anterior (más cercana a la entrada) y envían su salida a las neuronas de la capa posterior (más cercana a la salida de la red).
- ✓ Tenemos que definir el entrenamiento. La creación de una conexión implica que el peso de la misma pasa a tener un valor distinto de cero.  
Una conexión se destruye cuando su valor pasa a ser cero.
- ✓ Se dice que una red converge si la salida de la red es la salida deseada

## Aplicaciones

Las aplicaciones mas comunes que podemos tener en su uso son

- Reconocimiento y clasificación de patrones
- Diagnostico de imágenes medicas de tejidos cancerígenos y sanos.
- Análisis de tendencias de datos
- Pronostico de ventas
- Control de Procesos Industriales
- Administración de Riesgo en ventas
- Investigación sobre clientes



**El reconocimiento automático de emociones** en personas es un tema de interés en el área de visión por computadora debido a sus potenciales aplicaciones.

Tales como:

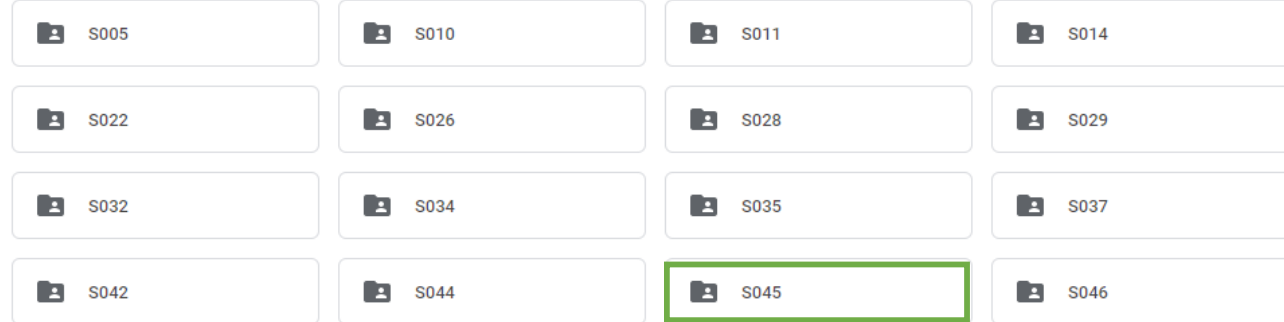
- Interacción Humano- Maquina
- Evaluación del dolor en atención Medica
- Detección de engaños
- Seguimiento de comportamiento en niños
- Detección de pérdida de atención en la conducción de autos.
- Entre otras



**Objetivo:** Desarrollar un prototipo capaz de realizar reconocimiento de emociones en imágenes utilizando un enfoque de redes neuronales tradicionales multicapa.

## Dataset Cohn-Kanade.


Mi unidad > Final\_SistemasInteligente > images ▾



Mi unidad > Final\_SistemasInteligente > images > S045 ▾



Carpetas



Mi unidad > ... > S045 > 001 ▾



S045\_001\_00000021.png



S045\_001\_00000022.png



S045\_001\_00000023.png



S045\_001\_00000024.png



S045\_001\_00000025.png



S045\_001\_00000026.png



S045\_001\_00000027.png



S045\_001\_00000028.png

## Preparación de la Base de Datos

Archivo llamado dataset.txt

S067	004	0
S089	003	0
S071	004	0
S075	008	0
S112	005	0
S029	001	0
S026	003	0
S504	001	0
S506	001	0
S111	006	0
S502	001	0
S136	005	0
S010	004	0
S034	003	0
S100	005	0
S090	007	0
S119	008	0
S066	005	0
S109	003	0
S014	003	0
S028	001	0
S501	001	0
S087	007	0
S113	008	0
S050	004	0
S082	005	0
S042	004	0
S134	003	0
S133	003	0
S011	004	0
S055	004	0
S022	005	0
S129	006	0

Representa una clasificación de Emociones

- 0.** *Enojo*
- 1.** *Desprecio*
- 2.** *Disgusto*
- 3.** *Miedo*
- 4.** *Alegría*
- 5.** *Tristeza*
- 6.** *Sorpresa*

De las n imágenes:

- ✓ **50%** -> La mitad de las primeras imágenes no usamos
- ✓ **50%** -> La mitad de las segundas imágenes usaremos para **TRAIN** y la penúltima imagen usamos para **TEST**

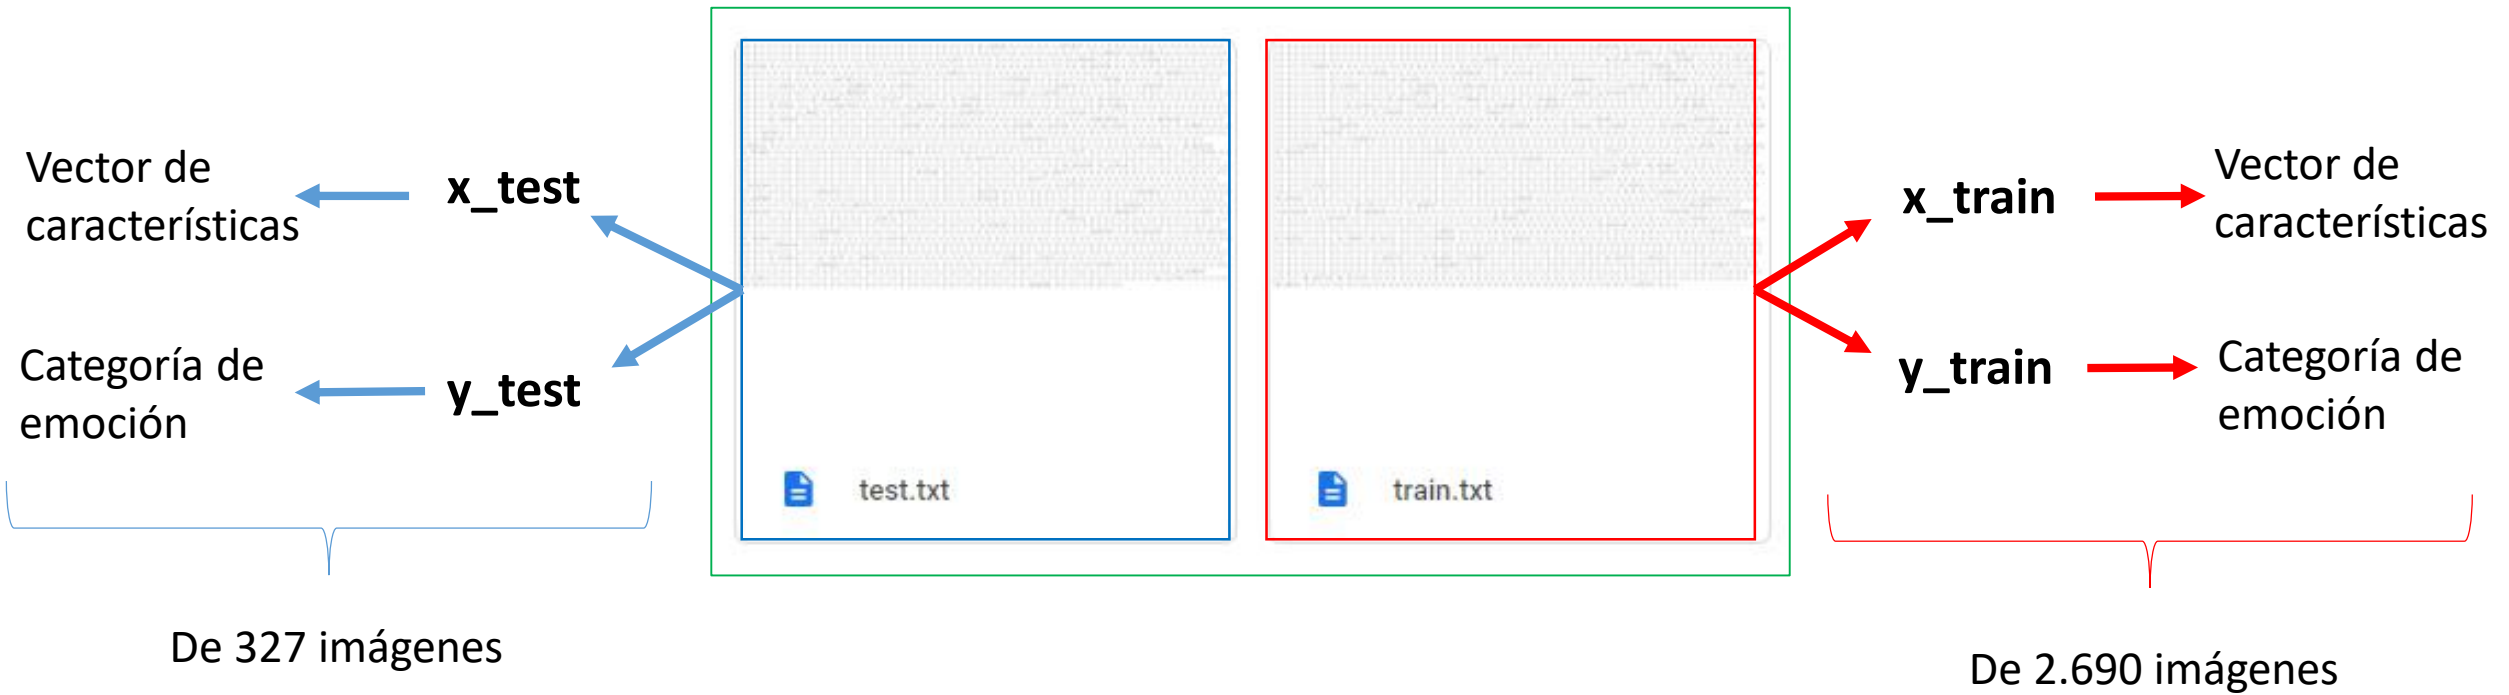
## Extracción de Características de una Imagen

```
from keras.applications.vgg16 import preprocess_input
from keras.applications.vgg16 import VGG16
import cv2 as cv
from google.colab.patches import cv2_imshow
```

```
[ ] #vamos a extraer las características de las imagenes y las retornamos
class Extractor():
    def __init__(self):
        self.modelo = VGG16(weights='imagenet', include_top=False)

    def extract(self, image):
        image = cv.cvtColor(image, cv.COLOR_BGR2RGB).astype(np.float32)
        image = cv.resize(image, (224, 224), interpolation = cv.INTER_LINEAR)
        image = np.array(image).reshape((1, image.shape[0], image.shape[1], image.shape[2]))
        image = preprocess_input(image)
        features = self.modelo.predict(image)
        features = features.flatten()
        return features
```

## Entrenamiento Supervisado



Los archivos generados anteriormente en donde se extrajeron las características y se entreno el modelo a partir de los archivos generados se realizaron a través de dos maneras:

- ❑ Una de las primeras manera se realizo a través de **Google Colaboratory** que es un entorno de máquinas virtuales basado en Jupyter Notebooks. Se pueden correr en la nube, es posible elegir correr nuestro notebook en una CPU, GPU o en una TPU de forma gratuita.  
En nuestro caso se realizo con Python 3 y en una GPU.  
Tiempo de duración : 40 mint.
- ❑ Otra de las maneras que se realizo es a través de manera local con el entorno de desarrollo **PyCharm** Community 2019.1 en donde se realizo con Python 3 y con CPU con procesador Intel Core i7 y teniendo memoria RAM de 8 GB.  
Tiempo de duración: 2 hs y 35 mint.

## Armamos Modelo de Red Neuronal Multicapa (MLP)

```
[ ] model = Sequential()

model.add(Dense(1470, input_dim=n, activation='relu'))
model.add(Dense(735, activation='relu'))
model.add(Dense(368, activation='relu'))
#model.add(Dropout(0.3))
model.add(Dense(92, activation='relu'))
model.add(Dense(7, activation='sigmoid'))

#Vamos a entrenar la red en base al Modelo definido anteriormente
print("\nEntrenando ...")
epocas = 100
#lr = 0.01
#decay = lr / epocas
#sgd = SGD(lr=lr, momentum=0.9, decay=decay, nesterov=False)
model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])

model.fit(x_train, y_train, epochs=epocas, batch_size=20)

#Evaluamos con el x,y tests
score = model.evaluate(x_test, y_test)

y_pred = model.predict(x_test)

print('\n>>>Esto es exactitud: \n %s: %.2f%%' % (model.metrics_names[1], score[1]*100))
print (model.predict(x_test).round())
```



```
model = Sequential()

model.add(Dense(1470, input_dim=n, activation='relu'))
model.add(Dense(735, activation='relu'))
model.add(Dense(368, activation='relu'))
model.add(Dropout(0.2))
model.add(Dense(92, activation='relu'))
model.add(Dense(7, activation='sigmoid'))

epocas = 100
#lr = 0.01
#decay = lr / epocas
#sgd = SGD(lr=lr, momentum=0.9, decay=decay, nesterov=False)

model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])

model.fit(x_train, y_train, epochs=epocas, batch_size=20)

score = model.evaluate(x_test, y_test)

print('esto es exactitud: \n %s: %.2f%%' % (model.metrics_names[1], score[1]*10))
```

## En Google Colaboraty...

```
[120] #cargarImagenes()
      ModeloSecuencial()
2090/2090 [-----] - 1s 384us/step - loss: 7.0522e-07 - acc: 1.0000
Epoch 79/100
2690/2690 [-----] - 1s 385us/step - loss: 6.8679e-07 - acc: 1.0000
Epoch 80/100
2690/2690 [-----] - 1s 387us/step - loss: 6.1101e-07 - acc: 1.0000
Epoch 81/100
2690/2690 [-----] - 1s 385us/step - loss: 5.3886e-07 - acc: 1.0000
Epoch 82/100
2690/2690 [-----] - 1s 382us/step - loss: 4.9116e-07 - acc: 1.0000
Epoch 83/100
2690/2690 [-----] - 1s 381us/step - loss: 4.5256e-07 - acc: 1.0000
Epoch 84/100
2690/2690 [-----] - 1s 384us/step - loss: 4.1205e-07 - acc: 1.0000
Epoch 85/100
2690/2690 [-----] - 1s 382us/step - loss: 3.8313e-07 - acc: 1.0000
Epoch 86/100
2690/2690 [-----] - 1s 384us/step - loss: 3.6900e-07 - acc: 1.0000
Epoch 87/100
2690/2690 [-----] - 1s 381us/step - loss: 3.5118e-07 - acc: 1.0000
Epoch 88/100
2690/2690 [-----] - 1s 380us/step - loss: 3.0609e-07 - acc: 1.0000
Epoch 89/100
2690/2690 [-----] - 1s 389us/step - loss: 2.7567e-07 - acc: 1.0000
Epoch 90/100
2690/2690 [-----] - 1s 386us/step - loss: 2.6401e-07 - acc: 1.0000
Epoch 91/100
2690/2690 [-----] - 1s 376us/step - loss: 2.6279e-07 - acc: 1.0000
Epoch 92/100
```

## En Pycharm...

```
Epoch 100/100

20/2690 [.....] - ETA: 15s - loss: 1.1146e-06 - acc: 1.0000
40/2690 [.....] - ETA: 15s - loss: 7.5549e-07 - acc: 1.0000
60/2690 [.....] - ETA: 15s - loss: 5.7419e-07 - acc: 1.0000
80/2690 [.....] - ETA: 15s - loss: 5.0441e-07 - acc: 1.0000
100/2690 [>.....] - ETA: 15s - loss: 4.3690e-07 - acc: 1.0000
120/2690 [>.....] - ETA: 15s - loss: 4.0432e-07 - acc: 1.0000
140/2690 [>.....] - ETA: 15s - loss: 3.6359e-07 - acc: 1.0000
160/2690 [>.....] - ETA: 14s - loss: 4.5002e-07 - acc: 1.0000
180/2690 [=>.....] - ETA: 14s - loss: 4.6955e-07 - acc: 1.0000
200/2690 [=>.....] - ETA: 14s - loss: 4.3452e-07 - acc: 1.0000
220/2690 [=>.....] - ETA: 14s - loss: 4.0640e-07 - acc: 1.0000
240/2690 [=>.....] - ETA: 14s - loss: 3.8246e-07 - acc: 1.0000
260/2690 [=>.....] - ETA: 14s - loss: 3.6221e-07 - acc: 1.0000
280/2690 [==>.....] - ETA: 14s - loss: 3.7317e-07 - acc: 1.0000
300/2690 [==>.....] - ETA: 14s - loss: 3.8564e-07 - acc: 1.0000
320/2690 [==>.....] - ETA: 14s - loss: 3.6936e-07 - acc: 1.0000
340/2690 [==>.....] - ETA: 13s - loss: 3.5500e-07 - acc: 1.0000
360/2690 [===>.....] - ETA: 13s - loss: 3.7385e-07 - acc: 1.0000
```

6: TODO 9: Version Control Terminal Python Console

## Resultados

-----  
En Carpeta de sujeto --->S071

En subcarpeta--->004

Prueba--->0

Prediccion--->0



**ENOJO**

-----  
En Carpeta de sujeto --->S154

En subcarpeta--->002

Prueba--->1

Prediccion--->1




**DESPRECIO**

-----  
En Carpeta de sujeto --->S067  
En subcarpeta--->006  
Prueba--->2  
Prediccion--->2



**DISGUSTO**

-----  
En Carpeta de sujeto --->S119  
En subcarpeta--->003  
Prueba--->3  
Prediccion--->3



**MIEDO**

-----  
En Carpeta de sujeto --->S108  
En subcarpeta--->005  
Prueba--->5  
Prediccion--->5



**TRISTEZA**

**ALEGRIA**

-----  
En Carpeta de sujeto --->S067  
En subcarpeta--->005  
Prueba--->4  
Prediccion--->4



-----  
En Carpeta de sujeto --->S077  
En subcarpeta--->001  
Prueba--->6  
Prediccion--->6



**SORPRESA**

## **Caso en donde se realiza una mala clasificación**

-----  
En Carpeta de sujeto --->S130


En subcarpeta--->012

Prueba--->2

Prediccion--->5

**DISGUSTO**

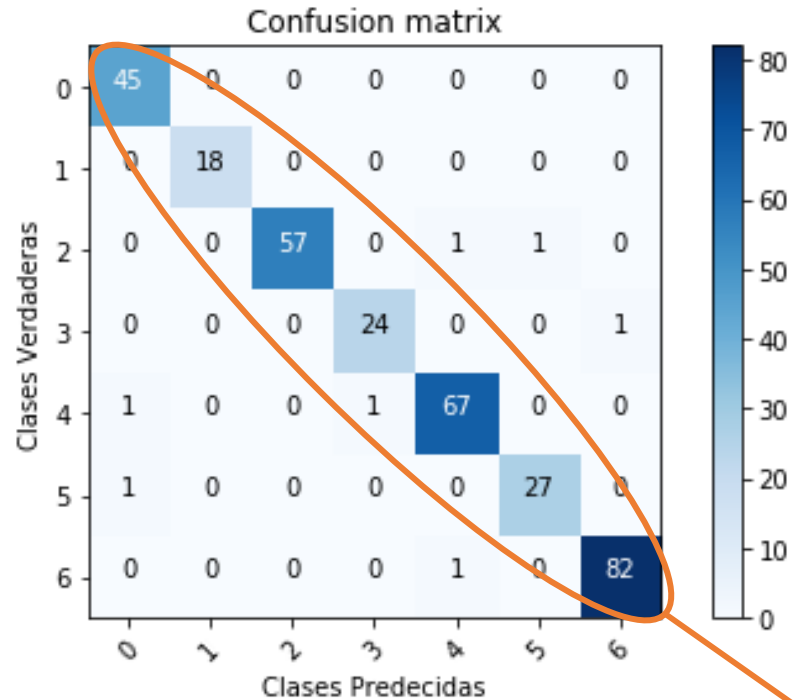
**TRISTEZA**





## Evaluación del Modelo

```
>>>Esto es exactitud:  
acc: 97.86%  
presicion:--->0.9785932721712538
```



```
32/327 [=>.....] - ETA: 1s  
160/327 [=====>.....] - ETA: 0s  
288/327 [=====>....] - ETA: 0s  
327/327 [=====] - 0s 802us/step
```


```
>>>Esto es presicion:  
acc: 97.55%
```

```
Process finished with exit code 0
```

Suma de diagonal

Precisión =  $\frac{\text{Suma de diagonal}}{327}$

- 0. Enojo
- 1. Desprecio
- 2. Disgusto
- 3. Miedo
- 4. Alegría
- 5. Tristeza
- 6. Sorpresa



- 0. Enojo
- 1. Desprecio
- 2. Miedo
- 3. Alegría
- 4. Tristeza
- 5. Sorpresa



```

model = Sequential()

model.add(Dense(1470, input_dim=n, activation='relu'))
model.add(Dense(735, activation='relu'))
model.add(Dense(368, activation='relu'))
#model.add(Dropout(0.3))
model.add(Dense(102, activation='relu'))
model.add(Dense(6, activation='sigmoid'))

print("\nEntrenando ...")
epocas = 100
#lr = 0.01
#decay = lr / epocas
#sgd = SGD(lr=lr, momentum=0.9, decay=decay, nesterov=False)
model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])

model.fit(x_train, y_train, epochs=epocas, verbose=1)

#Evaluamos con el modelo
score = model.evaluate(x_test, y_test, verbose=1)

y_pred = model.predict(x_test)

```

```

Epoch 89/100
2690/2690 [=====] - 1s 374us/step - loss: 6.0151e-07 - acc: 1.0000
Epoch 90/100
2690/2690 [=====] - 1s 374us/step - loss: 5.7027e-07 - acc: 1.0000
Epoch 91/100
2690/2690 [=====] - 1s 365us/step - loss: 5.5628e-07 - acc: 1.0000
Epoch 92/100
2690/2690 [=====] - 1s 368us/step - loss: 5.3443e-07 - acc: 1.0000
Epoch 93/100
2690/2690 [=====] - 1s 376us/step - loss: 5.0099e-07 - acc: 1.0000
Epoch 94/100
2690/2690 [=====] - 1s 381us/step - loss: 4.8169e-07 - acc: 1.0000
Epoch 95/100
2690/2690 [=====] - 1s 383us/step - loss: 4.7659e-07 - acc: 1.0000
Epoch 96/100
2690/2690 [=====] - 1s 380us/step - loss: 4.2777e-07 - acc: 1.0000
Epoch 97/100
2690/2690 [=====] - 1s 381us/step - loss: 4.0559e-07 - acc: 1.0000
Epoch 98/100
2690/2690 [=====] - 1s 370us/step - loss: 3.9316e-07 - acc: 1.0000
Epoch 99/100
2690/2690 [=====] - 1s 374us/step - loss: 3.6282e-07 - acc: 1.0000
Epoch 100/100
2690/2690 [=====] - 1s 374us/step - loss: 3.5859e-07 - acc: 1.0000
327/327 [=====] - 0s 520us/step

```

```

[ ]
for i in range(0, len(y_train), 1):
    y_train[i] = int(y_train[i])

    if(y_train[i] == 0):
        y_train[i] = 0
    elif((y_train[i] == 1) or (y_train[i] == 2)):
        y_train[i] = 1
    else:
        y_train[i] = y_train[i] - 1

y_train = np_utils.to_categorical(y_train)

x_test = np.array(x_test)
for i in range(0, len(y_test), 1):
    y_test[i] = int(y_test[i])
    if(y_test[i] == 0):
        y_test[i] = 0
    elif((y_test[i] == 1) or (y_test[i] == 2)):
        y_test[i] = 1
    else:
        y_test[i] = y_test[i] - 1
for i in y_test:
    print(i)
y_test = np_utils.to_categorical(y_test)
for i in y_test:
    print(i)

```

```
>>>Esto es exactitud:  
acc: 97.25%  
presicion::--->0.9724770642201835
```

